

第二章 产品设计与技术架构

一、 产品定位与核心价值

产品定位：面向半导体研发项目管理的“行业型 AI 副驾驶”。它不是通用待办工具，而是将芯片项目关键数据、行业规则与组织协同动作连接起来的项目控制中枢。

1.1 目标用户与关键任务

用户角色	关键任务	PM Agent 提供的价值
芯片研发 PM	识别交付风险、推进跨部门决策、对外同步	分钟级风险简报、自动组织协同、待办闭环
PMO / 研发管理层	掌握项目组合健康度、调配资源	统一健康度、里程碑与资源热力图
采购 / 封测接口人	处理供应商异常、确认替代方案	异常关联历史案例与可执行行动清单
客户验证负责人	对齐验证节奏与交期预期	以事实链路生成沟通口径与状态同步

1.2 核心价值：

价值维度	传统 PM 模式	PM Agent 副驾驶模式
风险发现	依赖手动刷多个系统，通常在异常暴露后处理	规则 + 趋势 + 语义信号融合，形成分钟级预警与 30 天前瞻
协同推进	拉群、约会、写议程、记纪要、催办均需人工完成	一句意图触发会议编排、资料检索、纪要与待办追踪
管理决策	依赖个人经验与碎片化汇报	项目健康度、影响范围、可选方案与风险成本同屏呈现
组织知识	经验随人员流动而流失	沉淀案例、规则、决策及执行结果，持续反哺模型

二、核心功能模块

2.1 风险感知 Agent

持续监听晶圆厂产能、封测排期、项目计划、客户反馈、良率、供应商交期和市场情报等数据。当检测到“BGA 基板交期延误 ≥ 14 天”等事件时，自动输出风险等级、影响节点、可能原因、建议响应时限及备选方案。

三层识别机制：阈值规则快速拦截高频风险；时序预测识别趋势性偏差；LLM 从纪要、群聊等非结构化文本中提取隐性信号。

风险卡片直达：以红/橙/黄等级呈现，并链接责任人、证据数据、历史类似案例与升级动作。

2.2 协同自动化 Agent

识别群聊或卡片中的协同意图，例如“针对 BGA 基板延迟，拉个紧急会”，随后完成参会人识别、忙闲校验、会议创建、议程生成、资料检索。会后自动生成结构化纪要、责任到人的待办和逾期提醒，并回写项目状态。

2.3 项目可视化指挥舱

为管理层、PMO 和项目负责人提供同源数据视图：全局健康度、红色预警项目、里程碑计划/实际偏差、资源热力、风险池与决策入口。支持从项目组合下钻至具体风险、责任人和行动状态，避免汇报“拼图化”。

2.4 决策模拟 Agent


围绕资源重分配、产能瓶颈、排期压缩、客户优先级与成本——风险权衡，输入可调节变量后给出交付时间、成本、风险和建议动作。首期先以规则化“方案对比卡”实现，后续接入蒙特卡洛、CPM 与预测模型。

三、系统总体技术架构

本方案不是单一聊天机器人，而是以“事件驱动 + 多 Agent 状态编排 + 企业知识增强”为核心的工程化 Agent 系统。架构遵循飞书原生接入优先、模型与框架可替换、数据与建议可追溯、关键动作人机共审四项原则；比赛阶段可在飞书 Aily 环境快速验证，企业部署阶段可平滑演进为独立后端服务。

3.1 技术栈总览与分层架构

技术栈总览：



架构说明：

飞书开放平台提供业务入口和交互终点；FastAPI 承担鉴权、事件接收、接口编排与审计；LangGraph 负责维护 Agent 状态机，每个 Agent 作为独立节点运行，通过条件路由完成风险分析、协同编排、报告生成等任务；当 Risk Agent 输出高风险事件后，系统自动进入 Meeting Agent，生成会议议程、调用飞书日历接口创建会议，并

将会议纪要交由 Report Agent 总结并同步至项目台账，实现 Agent 间的事件驱动闭环；LlamaIndex 负责企业知识检索；PostgreSQL、Milvus、Redis 分别承担业务事实、语义记忆与短期运行状态；LLM 层由飞书 Aily 与可替换的大模型共同提供。

技术层	建议方案	在本项目中的作用
前端与交互	飞书消息卡片 / 多维表格仪表盘；扩展可用 React + TypeScript + Ant Design	承载风险预警、项目指挥舱、PM 确认及管理层下钻
后端与网关	Python + FastAPI	承接 Webhook/Event API，封装飞书 API、Agent 工具与鉴权审计
Agent 编排	LangGraph；比赛环境可映射至 Aily Workflow	以状态图编排 Agent、条件路由、人工审批与失败重试
模型服务	飞书 Aily；GPT-4.1 / Qwen3 等可替换模型	完成意图识别、文本抽取、推理、总结与行动建议生成
RAG 与向量库	LlamaIndex + Milvus / ChromaDB	构建企业知识索引，召回历史案例与规则证据
业务数据与缓存	PostgreSQL + Redis	保存项目、风险、任务、审计记录；缓存会话与 Agent 状态
部署与运维	Docker；规模化时可选 Kubernetes	支持环境隔离、水平扩展、日志监控和灰度发布

3.2 Agent 技术架构：

每个业务 Agent 均以独立节点运行，并通过统一的 ProjectState（项目 ID、触发事件、风险上下文、检索证据、待审批动作、执行结果）共享上下文。LangGraph 负责维护状态机、执行条件路由和失败重试：规则命中或飞书事件进入 Risk Agent；若风险达到阈值，则路由至 Meeting Agent；会议结束事件再进入 Report Agent；涉及资源、供应商或对外沟通的动作统一进入 PM 审批节点。

Agent 节点	核心工具调用	输入 / 输出
----------	--------	---------

Risk Agent	规则引擎、预测服务、LLM 抽取、RAG 检索	输入：排期/交期/群聊等事件； 输出：风险等级、证据、影响与建议
Meeting Agent	飞书 Calendar API、Docs/Wiki 检索、IM API	输入：已确认的高风险； 输出：会议、议程、参会人与资料包
Report Agent	飞书妙记/Minutes、LLM 总结、Project/Base API	输入：会议转写； 输出：决策、待办、责任人、截止时间与状态回写
Decision Agent	情景模拟、RAG、审批 API	输入：管理层问题或方案变量； 输出：成本/交期/风险对比与建议
Human-in-the-loop	飞书消息卡片、Approval API	对外通知、供应商切换、资源调整等高影响动作必须由 PM 确认

示例闭环：Risk Agent 识别”BGA 基板交期延迟 ≥ 14 天”后，写入风险台账并检索相似供应案例；系统按条件边将任务送入 Meeting Agent，自动生成议程并调用飞书 Calendar API 建会；会议结束后，Report Agent 解析妙记转写，生成责任到人的待办并回写飞书项目/多维表格。整个过程由事件驱动，PM 在关键节点确认，不依赖单个 Agent 的长链条自由推理。

3.3 RAG 知识增强：

知识库覆盖飞书 Wiki、飞书文档、历史项目复盘、会议纪要、供应商评价、DDR5 项目经验、风险规则库及经授权的项目附件。接入时以文档类型、项目、阶段、时间、保密级别和来源链接作为元数据，确保检索结果可追溯、可按权限过滤。


处理流程：

原始文档 / 飞书 Wiki、Docs、Minutes → Document Loader → 清洗与结构化切分 → Embedding (text-embedding-3-large 或可替换中文向量模型) → Milvus 向量索引 + PostgreSQL 元数据 → Hybrid Retrieval (关键词 + 向量) → Reranker 重排 → Top-K 证据片段 → LLM 生成带来源的建议。

LlamaIndex 负责连接飞书文档加载器、节点切分、索引构建与检索链路；检索采用 Hybrid Retrieval，将精确的项目编号、供应商名称、工艺节点等关键词检索与语义向量检索结合，再通过 Reranker 提升召回质量。实时项目数据与 Top-K 历史证据共同输入 LLM，要求输出”风险判断——依据——相似案例——建议动作”四段式结果，从机制上降低幻觉并方便 PM 复核。

3.4 模型调用与风险决策流程

系统采用 Rule-based + LLM + RAG 的混合决策模式：规则引擎负责延期、节点超时、KPI 异常等确定性、高频检测；LLM 负责群聊、会议纪要、邮件摘要等复杂语义理解与原因归纳；RAG 为模型提供企业专属事实和历史案例。三者分工明确，避免把所有判断交给大模型。



3.5 飞书开放平台集成与安全治理

接口层通过飞书开放平台 Webhook 与 Event API 接收项目、群聊、日历和会议事件，并以服务端 Token / OAuth 授权调用 Project、Base、Calendar、IM、Minutes、Docs/Wiki 与 Approval 等接口。所有请求在 FastAPI 网关完成签名校验、权限映射、幂等处理与审计记录；对供应商替换、资源调整、客户外发等高风险操作，通过飞书消息卡片或审批流要求 PM 二次确认。

3.6 技术亮点

1. 多 Agent 协同：以 LangGraph 状态机替代单 Agent 串行对话，支持事件驱动、条件路由、可插拔 Agent 与失败恢复。
2. 企业级 RAG：将飞书知识与项目复盘统一索引，采用混合检索 + 重排 + 元数据权限过滤，实现可引用、可追溯的建议。
3. Rule + AI 混合识别：规则保证确定性异常的稳定检测，LLM 处理非结构化信号和推理，模型结果由企业知识证据约束。
4. Human-in-the-loop：将高影响动作显式建模为审批节点，在自动化效率与企业级安全之间建立可控边界。

技术边界：首期不替代 ERP/MES/PLM 等生产系统，不自动执行高风险采购或对外承诺；对外发送、供应商切换、资源调配等关键动作均保留人工确认与审批。

四、预期交付成果

4.1 MVP 工作台

基于飞书多维表格搭建，包含风险台账、项目健康度指标及可视化仪表盘。该平台将直接用于 NV685 等试点项目的日常运维，实现项目状态的可视化巡检，确保管理者能够实时掌握项目全貌

4.2 风险感知 Agent

集成封测、供应商管理、里程碑延误等首批高频场景的风险规则包。系统可自动触发预警卡片，附带详实的证据链接与清晰的升级机制，解决传统风控中信息滞后与责任不清的问题。

4.3 协同自动化 Agent

打通会议全生命周期管理流程。支持通过单一指令自动完成会议编排、智能生成议程与纪要，并同步进行待办事项的分派与催办，真正实现从“会议组织”到“任务落地”的无缝闭环。

4.4 行业知识库

沉淀并结构化存储典型案例、供应商评价数据、复盘模板及风险规则说明。该知识库支持按风险类型进行精准检索，并能基于历史数据自动生成多种解决方案的对比分析，为决策提供智力支持。

4.5 试点复盘报告

汇总试点期间的运行效果数据与一线用户反馈，梳理风险规则的迭代优化路径。报告将重点输出规模化推广的可行性分析与模型升级路线图，为下一阶段的全面落地提供战略依据。

五、与伏达半导体的深度共创方案

5.1 共创机制：业务专家与产品团队双向校准

共创主体	伏达半导体投入	项目团队投入	阶段性产出
业务专家组	PM、封测/采购接口人、PMO、IT/数据接口人参与场景访谈与规则确认	梳理流程、构建原型、沉淀风险字典与数据模型	场景清单、数据字段字典、风险规则 V1
试点用户组	在真实项目中使用预警卡片、协同流程与指挥舱，提供反馈	配置 Agent、监测使用数据、快速迭代	MVP、体验问题清单、效果数据
管理评审组	确认关键指标、审批边界及推广优先级	输出量化复盘与下一阶段路线图	试点评估报告、推广建议

5.2 分阶段共创路径

阶段	周期	重点工作	共创成果
P0 需求校准	第 1 - 2 周	访谈 PM/封测/采购；确定 NV685 关键数据与风险阈值	试点范围、数据字典、风险规则与验收指标

P1 MVP 搭建	第 3 - 5 周	搭建数据台账、风险 Agent、指挥舱与协同流程	可演示、可操作的端到端 MVP
P2 真实试运行	第 6 - 8 周	以真实/脱敏数据运行；收集预警和协同闭环反馈	规则优化、案例知识库、效果看板
P3 评估与扩展	第 9 - 10 周	复盘指标，明确可推广项目与决策模拟优先级	试点评估报告与规模化路线图

5.3 建议的联合验收指标

效率：高频风险从发现到通知的时延、会议与待办自动生成覆盖率、PM 每周用于信息汇总的时间下降比例。

质量：有效预警率、预警提前量、关键待办按时完成率、风险闭环率。

采纳：建议采纳率、管理层指挥舱访问与决策使用频次。

安全：权限控制、敏感信息脱敏、关键行动人工确认、审计记录完整率。

技术参考：

[1] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[EB/OL]. arXiv:2210.03629, 2022. <https://arxiv.org/abs/2210.03629>.

[2] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[EB/OL]. arXiv:2005.11401, 2020. <https://arxiv.org/abs/2005.11401>. arXiv

[3] LangChain. LangGraph: Build Resilient Language Model Agents[EB/OL]. GitHub, 2024. <https://github.com/langchain-ai/langgraph>. Reddit

[4] LlamaIndex. LlamaIndex: Data Framework for Large Language Model Applications[EB/OL]. GitHub, 2024. https://github.com/run-llama/llama_index. GitHub

[5] Zilliz. Milvus: A Cloud-Native Vector Database for Scalable Similarity Search[EB/OL]. GitHub, 2024. <https://github.com/milvus-io/milvus>.

[18] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[EB/OL]. arXiv:1706.03762, 2017. <https://arxiv.org/abs/1706.03762>.